Maestría en Inteligencia Artificial Aplicada

TC5035.10 — Proyecto Integrador (Grupo 10) · Trimestre septiembre – diciembre 2026

AVANCE 3 · BASELINE

Planograma: IA para detección de productos y ubicación

Alternativa Embeddings

Modelo de referencia para el reconocimiento de producto en recortes de anaquel: algoritmo, características, ajuste, métrica y desempeño mínimo

Equipo 48

Jesús Soto Medrano	A01794746
Germán Eduardo Rodríguez Vázquez	A01796325
Oscar Alberto Ramírez Anaya	A01795438

Profesora: Dra. Grettel Barceló Alonso

Asesor: Dr. Raúl Valente Ramírez

Sponsor: Dr. Juan Arturo Nolazco Flores, Director del Hub de Ciencia de Datos, Tecnológico de Monterrey

Organización: Bnext, Monterrey, Nuevo León

18 de octubre de 2026

Índice

1. Introducción 3

1.1 Propósito 3

1.2 Problema y datos 3

1.3 Preparación y partición 4

2. Algoritmo de la alternativa 4

2.1 Referencia de azar 4

2.2 Elección y justificación 5

2.3 Contraste con otros algoritmos 6

3. Importancia de las características 7

4. Sub y sobreajuste 9

5. Métrica adecuada para el problema 10

6. Desempeño mínimo 11

7. Conclusiones de la alternativa 11

Bibliografía 12

Índice de tablas

Tabla 1. Muestra de SKU-110K utilizada 3

Tabla 2. Protocolos de evaluación y su referencia de azar 5

Tabla 3. Representaciones comparadas con el mismo recorte y la misma galería 6

Tabla 4. Diagnóstico intrínseco del espacio de embeddings 8

Tabla 5. Set etiquetado sintético (600 clases × 7 vistas) 9

Tabla 6. Métricas por decisión 10

Tabla 7. DINOv2 ViT-S/14 frente a los pisos y metas de desempeño 11

Índice de figuras

Figura 1. Ejemplo de anaquel anotado y cajas por imagen según la partición 4

Figura 2. Vistas degradadas usadas en el protocolo A 5

Figura 3. Flujo de reconocimiento con embeddings y galería de referencias 6

Figura 4. Top-1 por modelo y tipo de degradación 7

Figura 5. Vecinos más cercanos de otras fotos con DINOv2 y con histograma HSV 7

Figura 6. Consistencia con la estructura del anaquel 9

Figura 7. Curva few-shot y rechazo de clases fuera de la galería 10

1. Introducción

1.1 Propósito

Este documento presenta una **alternativa al baseline del Avance 3** dentro de la fase de Ingeniería del modelo de CRISP-ML(Q) (Visengeriyeva et al., 2023). En lugar de entrenar un clasificador con un número fijo de clases, el producto de cada recorte de anaquel se reconoce comparando su **embedding** —un vector que resume su apariencia— contra una galería de referencias. La motivación es operativa: el surtido cambia con rapidez y un clasificador cerrado obliga a re-entrenar cada vez que entra un SKU; con embeddings, dar de alta un producto equivale a agregar sus fotos a la galería (Tonioni y Di Stefano, 2019). Se responden las mismas cinco preguntas del Avance 3: qué algoritmo usar, qué información es importante, si el modelo sub o sobreajusta, cuál es la métrica adecuada y cuál debe ser el desempeño mínimo.

Las libretas `01` a `05` y el paquete `pgemb` que respaldan cada cifra están en la carpeta `CODE` del proyecto.

1.2 Problema y datos

La tarea se plantea como **reconocimiento por recuperación**: dado el recorte de una posición, encontrar en la galería el SKU más parecido y decidir si es el esperado por el planograma, otro SKU o un producto desconocido. Para construir y medir el pipeline se usó **SKU-110K** (Goldman et al., 2019), el conjunto público de referencia para escenas de anaquel densas: 11 743 fotos de tiendas de varios países, divididas en 8 219 de entrenamiento, 588 de validación y 2 936 de prueba (Ultralytics, s.f.). Sus anotaciones son cajas de una sola clase; el «110K» se refiere a los SKUs distintos que aparecen en las fotos, no a etiquetas. Por eso SKU-110K sirve para el detector agnóstico y para medir propiedades de los embeddings, pero no trae la identidad de cada producto. Se trabajó con una muestra de 390 imágenes (Tabla 1, Figura 1).

Tabla 1. Muestra de SKU-110K utilizada

Partición	Imágenes	Cajas	Cajas por imagen (mín. / mediana / máx.)	Uso en este reporte
Entrenamiento	253	37 129	81 / 139 / 375	Reservada para el ajuste fino
Validación	18	3 086	111 / 143 / 466	Galería de evaluación
Prueba	119	17 841	101 / 137 / 302	Galería de evaluación
Total	**390**	**58 056**	**81 / 138 / 466**	

> **MANEJO DE DATOS**
>
> SKU-110K se distribuye para uso académico y no comercial. Este reporte no usa imágenes de Bnext; las cifras del baseline que se citan provienen del Avance 3. El mismo pipeline puede ejecutarse dentro del servidor de Bnext sobre sus recortes etiquetados, sin que las imágenes salgan de su infraestructura.

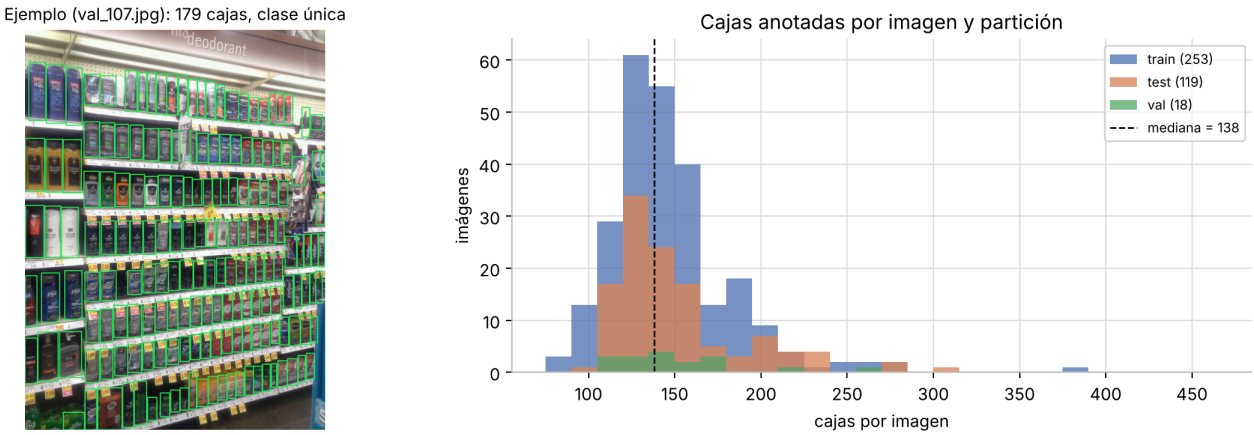


Figura 1. Ejemplo de anaquel con sus cajas anotadas y cajas por imagen según la partición. Elaboración propia con datos de SKU-110K (Goldman et al., 2019).

1.3 Preparación y partición

Cada caja se recorta de la imagen **a resolución completa**: la caja mediana mide 103 × 180 px y solo el 1.7 % tiene menos de 32 px de ancho, mientras que al reducir la foto a 640 px para un detector el 93 % quedaría por debajo de ese tamaño. El recorte se lleva a 224 × 224 px con *letterbox*, para no deformar envases alargados (relación alto/ancho mediana de 1.8), y se normaliza con la media y la desviación de ImageNet. Cada modelo produce un vector normalizado L2, de modo que la similitud coseno es un producto punto. Validación y prueba forman la galería de evaluación: 137 imágenes y 20 927 recortes. La partición de entrenamiento queda reservada para el ajuste fino de la siguiente fase; ningún modelo de este reporte se ajustó con estas imágenes.

2. Algoritmo de la alternativa

2.1 Referencia de azar

Sin etiquetas de SKU, los modelos se compararon con cuatro protocolos automáticos (libretas 03 y 05), cada uno con su referencia de azar (Tabla 2). En el protocolo A se excluyen de la galería los demás recortes de la misma foto, porque pueden ser el mismo SKU sin etiquetar. Todos los modelos quedan varios órdenes de magnitud por encima del azar (secciones 2.3 y 4).

Tabla 2. Protocolos de evaluación y su referencia de azar

Protocolo	Qué mide	Tamaño	Azar
A. Vistas sintéticas	Recuperar el recorte original desde una vista degradada (Figura 2)	1 500 consultas × 10 vistas; galería de 20 927 recortes	top-1 ≈ 5×10^{-5}
B. Diagnóstico intrínseco	Estructura del espacio vectorial	20 927 recortes	—
C. Consistencia con el anaquel	Facings contiguos del mismo tamaño frente a pares distintos	5 233 positivos; 20 000 negativos difíciles y 20 000 fáciles	AUROC 0.5; TPR 0.01 a FPR 1 %
D. Set etiquetado sintético	Identificación, verificación, pocas referencias y SKUs desconocidos	600 clases × 7 vistas = 4 200 muestras	top-1 ≈ 0.0014; con k = 1, 1/600



Figura 2. Vistas degradadas usadas en el protocolo A: caja desalineada, desenfoque, baja resolución, JPEG, color y luz, perspectiva, oclusión, reflejo y combinación de dos o tres de ellas. Elaboración propia con datos de SKU-110K.

2.2 Elección y justificación

Se eligió **DINOv2 ViT-S/14 congelado** (Oquab et al., 2024) con búsqueda por vecino más cercano o por prototipo en similitud coseno (Figura 3). La elección responde a las características del problema:

- **Conjunto abierto.** El número de SKUs no es fijo. Con un encoder y una galería, un SKU nuevo se agrega con sus fotos y sin re-entrenar (Tonioni y Di Stefano, 2019; Zhang et al., 2026).
- **Robustez.** Tiene el mejor promedio en las nueve degradaciones (top-1 de 0.915) y casi no se afecta por una caja desalineada (0.977), un cambio de color o luz (1.000), una oclusión (0.980) o un reflejo (0.995) (Figura 4).
- **Semántica de producto.** Recupera el mismo producto en otras fotos aunque cambien el ángulo y la luz; un descriptor de color recupera cualquier empaque del mismo tono (Figura 5).
- **Pocas referencias.** Es el mejor de los modelos profundos con una sola foto por SKU (top-1 de 0.837 con k = 1 en el protocolo D).
- **Costo.** Usa 384 dimensiones (la galería de 20 927 recortes ocupa 16 MB en float16) y procesa un recorte en 0.93 ms en la GPU del equipo. También corre en CPU, lo que importa porque el servidor de Bnext no tiene GPU (Avance 3).
- **Sin etiquetas en el preentrenamiento.** Al ser auto-supervisado, sus características no se sesgan hacia las 1 000 clases de ImageNet.

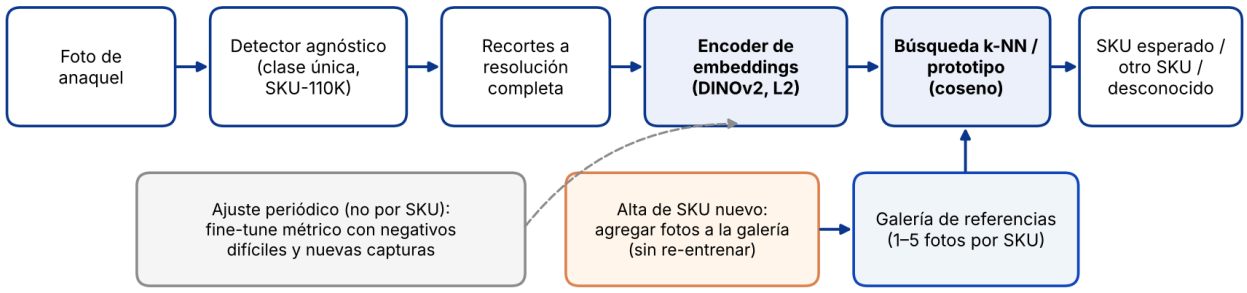


Figura 3. Flujo de reconocimiento con embeddings. El detector y el encoder se ajustan de forma periódica; el alta de un SKU solo agrega referencias a la galería. Elaboración propia.

2.3 Contraste con otros algoritmos

Se contrastaron siete representaciones con el mismo recorte y la misma galería (Tabla 3): tres descriptores clásicos —histograma HSV (Swain y Ballard, 1991), HOG (Dalal y Triggs, 2005) y miniatura RGB (Torralba et al., 2008)—, dos redes supervisadas en ImageNet —ResNet-50 (He et al., 2016) y EfficientNet-B0 (Tan y Le, 2019)— y dos tamaños de DINOv2.

Tabla 3. Representaciones comparadas con el mismo recorte y la misma galería

Modelo	Familia	Dim.	Parám. (M)	ms / recorte	Robustez promedio (A)	Top-1 combinada (A), IC 95 %	AUROC anaquel (C)
DINOv2 ViT-S/14	**Auto-supervisado**	**384**	**22.1**	**0.93**	**0.915**	**0.665 (0.641–0.689)**	**0.923**
DINOv2 ViT-B/14	Auto-supervisado	768	86.6	2.13	0.898	0.638 (0.616–0.662)	0.919
EfficientNet-B0	Supervisado ImageNet	1 280	4.0	10.75*	0.895	0.617 (0.593–0.641)	0.930
ResNet-50	Supervisado ImageNet	2 048	23.5	0.98	0.883	0.581 (0.556–0.606)	0.924
HOG	Clásico	3 780	—	1.84	0.887	0.799 (0.779–0.820)	0.889
Histograma HSV	Clásico	1 024	—	0.13	0.884	0.692 (0.669–0.715)	0.883
Miniatura RGB	Clásico	1 536	—	0.06	0.833	0.695 (0.671–0.719)	0.853

En negritas, la alternativa elegida. Robustez promedio: top-1 medio en las nueve degradaciones. IC por bootstrap de las 1 500 consultas. Tiempos de la libreta 02: modelos profundos en la GPU del equipo, clásicos en CPU. *El tiempo de EfficientNet-B0 es atípico para su tamaño y se volverá a medir.

Los modelos profundos dominan en robustez promedio y en consistencia con el anaquel. Los clásicos ganan en la degradación combinada: HOG alcanza 0.799 y supera a la miniatura RGB con diferencia significativa (McNemar: 264 contra 107 consultas discordantes, $p < 10^{-15}$). Esa ventaja no significa que reconozcan mejor el producto. Trabajan sobre recortes reducidos a 64 × 128 o 16 × 32 px, así que el desenfoque y la baja resolución casi no los afectan, y la prueba solo pide encontrar *el mismo* recorte, no distinguir dos productos parecidos. La Figura 5 lo muestra: con la misma consulta, el histograma HSV

devuelve empaques rojos de otras marcas, mientras que DINOv2 devuelve el mismo producto en otras fotos.

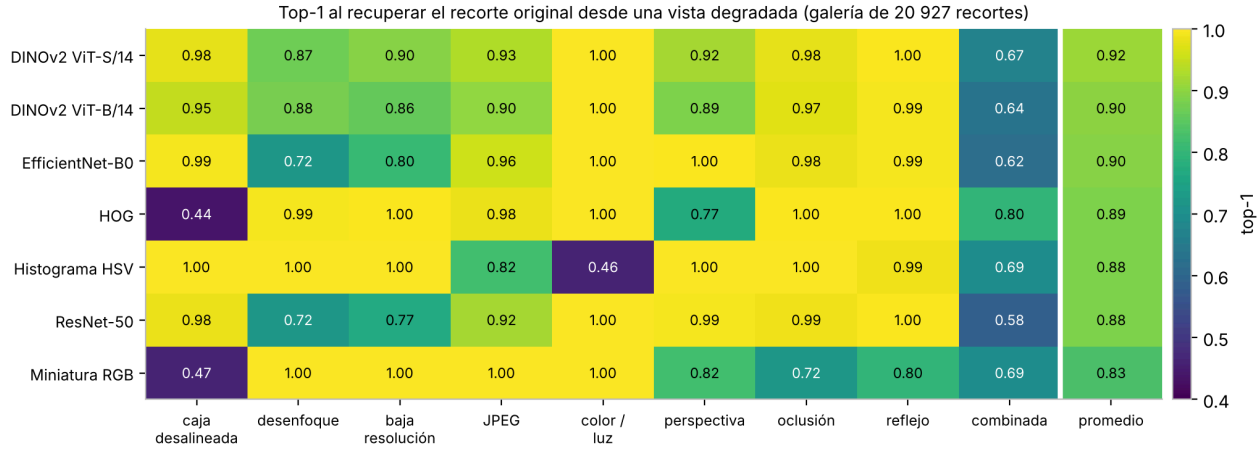


Figura 4. Top-1 por modelo y tipo de degradación al recuperar el recorte original entre 20 927 recortes; la última columna es el promedio sin la copia limpia de control. Elaboración propia con datos de SKU-110K.



Figura 5. Vecinos más cercanos de otras fotos para las mismas tres consultas (borde negro) con DINOv2 ViT-S/14 y con histograma HSV. Elaboración propia con datos de SKU-110K.

3. Importancia de las características

En un embedding las características no son variables individuales, sino la información que la representación conserva o descarta. Se analizaron dos aspectos: a qué variaciones es invariante cada modelo (Figura 4) y cómo está estructurado su espacio vectorial (Tabla 4).

El color es la señal más frágil fuera de la foto original. El histograma HSV, que depende solo de él, cae a 0.461 cuando cambian el tono y la iluminación, justo lo que varía entre tiendas y horarios. Coincide con el Avance 3, donde los histogramas HSV fueron la familia más importante del baseline: el color separa bien productos dentro de una misma captura, pero es una base débil para reconocerlos en otra. La forma (HOG) y la miniatura RGB dependen de la posición exacta y caen a 0.439 y 0.467 cuando la caja se desplaza o escala, como ocurre con un detector real. Las redes supervisadas son robustas a la caja y al color, pero pierden con desenfoque (0.717) y baja resolución (0.766–0.805). DINOv2 es la más equilibrada; su punto débil también es la pérdida de detalle (0.861–0.897), que es lo que debe cubrir el ajuste fino con aumentos de desenfoque y resolución.

Tabla 4. Diagnóstico intrínseco del espacio de embeddings

Modelo	Dim.	Rango efectivo	Uso de dimensiones	Anisotropía	Hubness (asimetría de N_{10})	Máx. N_{10}	Uniformidad
DINOv2 ViT-S/14	**384**	**291.7**	**76 %**	**0.293**	**1.88**	**76**	**−2.68**
DINOv2 ViT-B/14	768	563.6	73 %	0.266	2.04	91	−2.80
EfficientNet-B0	1 280	919.5	72 %	0.202	1.52	67	−3.08
ResNet-50	2 048	1 238.4	60 %	0.368	2.42	119	−2.39
HOG	3 780	1 729.0	46 %	0.091	8.74	483	−3.50
Histograma HSV	1 024	521.0	51 %	0.188	1.26	52	−3.05
Miniatura RGB	1 536	591.3	38 %	0.063	3.72	196	−3.39

Rango efectivo según Roy y Vetterli (2007); anisotropía: coseno medio entre recortes al azar; N_{10}: veces que un recorte aparece entre los 10 vecinos de otro, en una muestra de 5 000 recortes (Radovanović et al., 2010); uniformidad según Wang e Isola (2020), más negativo es más uniforme.

La Tabla 4 muestra tres limitaciones conocidas de los embeddings:

- **Hubness.** En alta dimensión unos pocos puntos aparecen como vecinos de casi todos (Radovanović et al., 2010). En HOG, dentro de una muestra de 5 000 recortes, uno solo aparece entre los 10 vecinos de 483 de ellos, lo que vuelve poco confiable su búsqueda k-NN.
- **Anisotropía.** Si el coseno medio entre recortes al azar es alto (0.37 en ResNet-50 y 0.29 en DINOv2-S), un umbral global de similitud no funciona y hay que calibrarlo por SKU o por categoría.
- **Capacidad.** La dimensión acota cuántas combinaciones de vecinos puede representar un embedding (Weller et al., 2026), y los encoders visuales generales confunden pares que difieren en texto, color o detalle fino (Tong et al., 2024). Para variantes del mismo envase conviene una segunda etapa que reordene los primeros candidatos con OCR o rasgos locales.

DINOv2-S aprovecha el 76 % de sus dimensiones, la proporción más alta del grupo. La consistencia con el anaquel (Figura 6) mide si los facings contiguos del mismo tamaño, que casi siempre son el mismo producto o la misma línea, quedan más cerca que pares claramente distintos. Los modelos profundos superan a los clásicos (AUROC de 0.919 a 0.930 contra 0.853 a 0.889), pero con 1 % de falsos positivos

ninguno recupera más del 43 % de los pares: las variantes de sabor o color del mismo envase siguen siendo el caso difícil.

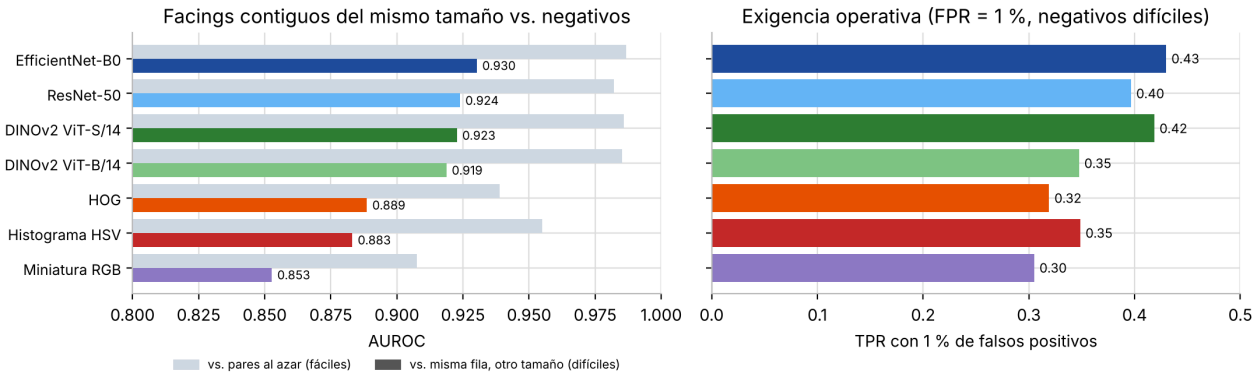


Figura 6. Consistencia con la estructura del anaquel: AUROC de facings contiguos del mismo tamaño frente a negativos fáciles y difíciles, y TPR con 1 % de falsos positivos. Elaboración propia con datos de SKU-110K.

4. Sub y sobreajuste

La alternativa no entrena parámetros con los datos del proyecto: los encoders se usan congelados y la galería solo almacena vectores. Por eso **no hay sobreajuste** a los SKUs de entrenamiento. El riesgo es el contrario, un **subajuste de dominio**: las características son genéricas y no están especializadas en empaques de anaquel. Dos señales lo muestran. En la degradación combinada los modelos profundos bajan a un top-1 de 0.58 a 0.67, y en el protocolo D su OSCR (0.70 a 0.77) queda muy por debajo de su top-1 de identificación (0.94 a 0.98) (Tabla 5). La literatura cuantifica el margen disponible: en un catálogo de Walmart, DINOv3 sin ajustar logra 53.83 % de top-1 y 80.73 % tras un ajuste contrastivo en tres etapas, y conserva 80.23 % con productos excluidos del entrenamiento (Zhang et al., 2026).

Tabla 5. Set etiquetado sintético (600 clases × 7 vistas)

Modelo	Top-1 LOO	MAP@R	AUROC verif.	TPR a FPR 1 %	Top-1 k = 1	Top-1 k = 3	AUROC open-set	OSCR
DINOv2 ViT-S/14	**0.970**	**0.793**	**0.994**	**0.914**	**0.837**	**0.950**	**0.864**	**0.765**
DINOv2 ViT-B/14	0.965	0.771	0.992	0.883	0.809	0.932	0.838	0.729
EfficientNet-B0	0.975	0.739	0.990	0.872	0.791	0.922	0.844	0.713
ResNet-50	0.940	0.740	0.978	0.814	0.781	0.919	0.817	0.699
Histograma HSV	0.968	0.906	0.995	0.951	0.909	0.972	0.931	0.886
HOG	0.910	0.726	0.976	0.772	0.749	0.897	0.826	0.702
Miniatura RGB	0.884	0.706	0.975	0.786	0.734	0.866	0.818	0.680

Cada clase es un recorte de prueba con su versión limpia y seis vistas degradadas. LOO: cada muestra consulta contra todas las demás. k: referencias por clase (prototipo). Open-set: 25 % de las clases fuera de la galería.

El protocolo D favorece al histograma HSV (MAP@R de 0.906) por la misma razón que el protocolo A: sus clases son vistas de un mismo recorte y comparten la paleta exacta. No mide la

confusión entre variantes reales, que es donde el color falla (Figura 5); por eso no cambia la elección.

La **curva few-shot** (Figura 7) cumple el papel de la curva de aprendizaje: con DINOv2-S el top-1 sube de 0.837 con una referencia a 0.950 con tres y a 0.962 con cinco. La meseta a partir de k = 3 indica que el alta de un SKU nuevo cuesta unas tres fotos. Cuando se ajuste el encoder, el sobreajuste se controlará con una partición disjunta por SKU (vistos contra no vistos), congelando la mitad inferior del backbone como en Zhang et al. (2026) y eligiendo el punto de parada en validación, nunca en prueba (Musgrave et al., 2020).

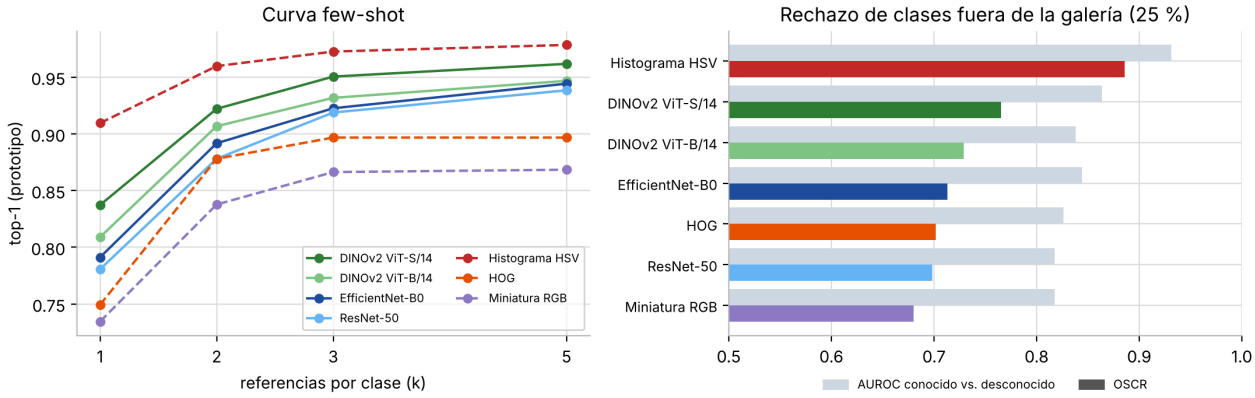


Figura 7. Top-1 según el número de referencias por clase y rechazo de clases fuera de la galería en el set etiquetado sintético. Elaboración propia con datos de SKU-110K.

5. Métrica adecuada para el problema

Con embeddings la salida no es una clase sino una lista ordenada de candidatos con su similitud. Las métricas deben cubrir las decisiones de la Figura 3 (Tabla 6). La métrica principal es el **MAP@R entre fotos distintas**: premia que todas las referencias del SKU queden arriba, mientras que el top-1 se satura (Musgrave et al., 2020). En el protocolo D todos los modelos superan 0.88 de top-1, pero su MAP@R va de 0.71 a 0.91. Medir entre fotos distintas evita el optimismo de comparar un recorte con su vecino de la misma foto.

Tabla 6. Métricas por decisión

Decisión	Métrica	Por qué
Identificar el SKU de la posición	**MAP@R entre fotos distintas**; top-1 y top-3	Mide el orden completo de candidatos y no se satura como el top-1
Verificar contra el planograma	**TPR a FPR = 1 %**	Fija el costo de las alertas falsas que revisa el personal y mide cuántos aciertos se obtienen con ese costo
Detectar SKUs no dados de alta	**AUROC conocido/desconocido** y OSCR	Un producto nuevo debe reportarse como desconocido, no como el SKU más parecido (Dhamija et al., 2018; Vaze et al., 2022)
Comparar con el baseline	F1 macro y top-3 con k-NN	Misma partición de prueba de Bnext que el Avance 3

Los modelos se comparan sobre las mismas consultas, con intervalos de confianza por bootstrap (Efron y Tibshirani, 1993) y prueba de McNemar para aciertos pareados (McNemar, 1947).

6. Desempeño mínimo

Se fijan tres niveles. El primero es el **piso estadístico** de la Tabla 2, que todos los modelos superan por varios órdenes de magnitud. El segundo es el **piso del baseline**: en la misma partición de prueba de Bnext, la alternativa debe igualar el F1 macro de 0.881 y el top-3 de 0.951 del Avance 3, porque su ventaja es operativa y no debe costar exactitud. El tercero son **metas propias de la alternativa**, propuestas por el equipo y pendientes de validar con el líder técnico de Bnext (Tabla 7). La meta de verificación retoma la exactitud de 0.85 por posición del Avance 0, y la de latencia permite procesar una foto de unos 150 productos en menos de un segundo.

Tabla 7. DINOv2 ViT-S/14 frente a los pisos y metas de desempeño

Criterio	Meta	DINOv2-S	Evidencia	Estado
F1 macro en prueba de Bnext	≥ 0.881	—	Por medir	**Pendiente**
Top-3 en prueba de Bnext	≥ 0.951	—	Por medir	**Pendiente**
AUROC conocido/desconocido	≥ 0.90	0.864	Protocolo D	**No cumple**
TPR a FPR 1 %, verificación	≥ 0.85	0.914	Protocolo D	**Cumple (indicativo)**
TPR a FPR 1 %, pares difíciles de anaquel	≥ 0.85	0.418	Protocolo C (etiquetas débiles)	**No cumple**
Top-1 con tres referencias por SKU	≥ 0.881	0.950	Protocolo D	**Cumple (indicativo)**
Latencia por recorte	≤ 5 ms	0.93 ms	Libreta 02	**Cumple**

La alternativa cumple la latencia y, de forma indicativa, las metas de pocas referencias y de verificación del set sintético. No cumple el rechazo de desconocidos ni la verificación de pares difíciles, que son los dos puntos que debe atacar el ajuste fino. **El desempeño mínimo para adoptar la alternativa queda fijado en igualar al baseline en la partición de prueba de Bnext (F1 macro ≥ 0.881 y top-3 ≥ 0.951) con un AUROC conocido/desconocido ≥ 0.90.** Las cifras de SKU-110K sirven para elegir el modelo, no para aprobarlo.

7. Conclusiones de la alternativa

1. **Algoritmo.** DINOv2 ViT-S/14 congelado con búsqueda por vecino más cercano o por prototipo en similitud coseno. Admite SKUs nuevos sin re-entrenar, es el más robusto en promedio (0.915) y procesa un recorte en menos de 1 ms.
2. **Características.** El color separa productos dentro de una foto, pero falla entre tiendas (0.461 con cambio de luz); la forma depende de que la caja esté bien alineada. DINOv2 es la representación más equilibrada; su debilidad es la pérdida de detalle por desenfoque o baja resolución.

3. **Ajuste.** Sin entrenamiento no hay sobreajuste; el riesgo es un subajuste de dominio. Tres referencias por SKU alcanzan la meseta de la curva few-shot.
4. **Métrica.** MAP@R entre fotos distintas para identificar, TPR a FPR = 1 % para verificar contra el planograma y AUROC/OSCR para detectar SKUs no dados de alta; F1 macro y top-3 para comparar con el baseline.
5. **Desempeño mínimo.** Igualar al baseline (0.881 y 0.951) en la partición de Bnext con AUROC open-set ≥ 0.90. Hoy no se alcanza el rechazo de desconocidos (0.864) y falta la medición con datos de Bnext.

Siguientes pasos. Ejecutar el harness de la libreta 05 sobre los 2 887 recortes etiquetados de Bnext, con referencias de entrenamiento y consultas de prueba, dentro de su servidor; DINOv2-S corre en CPU. Etiquetar al menos 100 SKUs de SKU-110K con la libreta 04b para medir el reconocimiento entre fotos distintas. Ajustar el encoder con aprendizaje métrico, negativos difíciles de la misma marca y aumentos de desenfoque y baja resolución. Agregar una etapa de reordenamiento con OCR para variantes del mismo envase y calibrar los umbrales por categoría.

Bibliografía

Dalal, N., y Triggs, B. (2005). Histograms of oriented gradients for human detection. En *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition* (Vol. 1, pp. 886–893). IEEE. https://doi.org/10.1109/CVPR.2005.177

Dhamija, A. R., Günther, M., y Boult, T. E. (2018). Reducing network agnostophobia. En *Advances in Neural Information Processing Systems* (Vol. 31). Curran Associates. https://arxiv.org/abs/1811.04110

Efron, B., y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Goldman, E., Herzig, R., Eisenschtat, A., Goldberger, J., y Hassner, T. (2019). Precise detection in densely packed scenes. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 5227–5236). IEEE. https://doi.org/10.1109/CVPR.2019.00537

He, K., Zhang, X., Ren, S., y Sun, J. (2016). Deep residual learning for image recognition. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778). IEEE. https://doi.org/10.1109/CVPR.2016.90

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika, 12*(2), 153–157. https://doi.org/10.1007/BF02295996

Musgrave, K., Belongie, S., y Lim, S.-N. (2020). A metric learning reality check. En *Computer Vision – ECCV 2020* (pp. 681–699). Springer. https://doi.org/10.1007/978-3-030-58595-2_41

Oquab, M., Darcet, T., Moutakanni, T., Vo, H. V., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., … Bojanowski, P. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. https://arxiv.org/abs/2304.07193

Radovanović, M., Nanopoulos, A., y Ivanović, M. (2010). Hubs in space: Popular nearest neighbors in high-dimensional data. *Journal of Machine Learning Research, 11*, 2487–2531.

Roy, O., y Vetterli, M. (2007). The effective rank: A measure of effective dimensionality. En *15th European Signal Processing Conference* (pp. 606–610). EURASIP.

Soto Medrano, J., Rodríguez Vázquez, G. E., y Ramírez Anaya, O. A. (2026). *Planograma: IA para detección de productos y ubicación. Avance 3: Baseline* [Reporte de proyecto]. Tecnológico de Monterrey.

Swain, M. J., y Ballard, D. H. (1991). Color indexing. *International Journal of Computer Vision, 7*(1), 11–32. https://doi.org/10.1007/BF00130487

Tan, M., y Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *Proceedings of the 36th International Conference on Machine Learning* (pp. 6105–6114). PMLR.

Tong, S., Liu, Z., Zhai, Y., Ma, Y., LeCun, Y., y Xie, S. (2024). Eyes wide shut? Exploring the visual shortcomings of multimodal LLMs. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 9568–9578). IEEE. https://arxiv.org/abs/2401.06209

Tonioni, A., y Di Stefano, L. (2019). Domain invariant hierarchical embedding for grocery products recognition. *Computer Vision and Image Understanding, 182*, 81–92. https://doi.org/10.1016/j.cviu.2019.03.005

Torralba, A., Fergus, R., y Freeman, W. T. (2008). 80 million tiny images: A large data set for nonparametric object and scene recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 30*(11), 1958–1970. https://doi.org/10.1109/TPAMI.2008.128

Ultralytics. (s.f.). *SKU-110K dataset*. Recuperado el 21 de octubre de 2026, de https://docs.ultralytics.com/datasets/detect/sku-110k/

Vaze, S., Han, K., Vedaldi, A., y Zisserman, A. (2022). Open-set recognition: A good closed-set classifier is all you need? En *International Conference on Learning Representations*. https://arxiv.org/abs/2110.06207

Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., y Plöd, M. (2023). *CRISP-ML(Q). The ML lifecycle process*. MLOps. INNOQ. https://ml-ops.org/content/crisp-ml

Wang, T., e Isola, P. (2020). Understanding contrastive representation learning through alignment and uniformity on the hypersphere. En *Proceedings of the 37th International Conference on Machine Learning* (pp. 9929–9939). PMLR.

Weller, O., Boratko, M., Naim, I., y Lee, J. (2026). On the theoretical limitations of embedding-based retrieval. En *International Conference on Learning Representations*. https://arxiv.org/abs/2508.21038

Zhang, A., Mazumder, J., y Lomakin, K. (2026). *Bridging the catalog-to-real gap: Scalable product recognition via multi-stage contrastive learning* [Preprint]. arXiv. https://arxiv.org/abs/2607.09888